Módulo 4: Adicionar uma camada de computação

Seção 6: Adicionar armazenamento a uma instância do Amazon EC2



Visão geral do armazenamento do Amazon EC2





Este volume sempre contém o SO convidado



instâncias



Amazon EBS
(Somente compatível com SSD)



Uma instância do EC2 *sempre* terá um volume raiz e, *opcionalmente*, pode ter um ou mais volumes de dados.

Volumes de dados

Para dados acessados por uma única instância





Armazenamen to de instâncias

Amazon EBS

Para dados acessíveis de várias instâncias





Amazon Elastic File System (Amazon EFS) [Linux]

Amazon FSx for Windows File Server

Armazenamento de instâncias



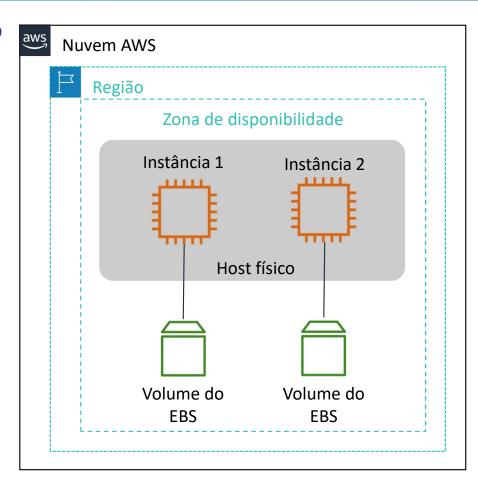
- Um armazenamento de instâncias fornece armazenamento não persistente a uma instância
 - Os dados são armazenados no mesmo servidor físico em que a instância é executada
- Características
 - Armazenamento temporário em nível de bloco
 - Usa HDD ou SSD
 - Os dados do armazenamento de instâncias serão perdidos quando a instância for interrompida ou encerrada
- Exemplos de casos de uso
 - Buffers
 - Cache
 - Dados transitório



Amazon EBS



- Os volumes do Amazon EBS fornecem armazenamento persistente conectado à rede para uma instância do EC2.
- Características
 - Armazenamento em nível de bloqueio persistente
 - Pode associar a qualquer instância na mesma zona de disponibilidade
 - Usa HDD ou SSD
 - Pode ser criptografado
 - Suporte a snapshots que persistem no S3
 - Os dados persistem independentemente da vida útil da instância
- Exemplos de casos de uso
 - Banco de dados autônomo
 - Armazenamento de dados de aplicações gerais



Tipos de volume Amazon EBS compatíveis com SSD



Os volumes compatíveis com SSD do Amazon EBS são adequados para casos de uso em que o foco da performance está no IOPS.

	SSD de uso geral (gp2)	SSD de IOPS provisionadas (io1)
Descrição	Equilibra preço e performance para uma ampla variedade de cargas de trabalho	 Volume SSD de melhor performance Adequado para cargas de trabalho de missão crítica, de baixa latência ou de alta taxa de transferência
Casos de uso	 Recomendado para a maioria das cargas de trabalho Pode ser um volume de inicialização 	 Aplicações essenciais de negócios que exigem performance de IOPS sustentada Cargas de trabalho de banco de dados grandes Cargas de trabalho transacionais Pode ser um volume de inicialização

Tipos de volume compatíveis com HDD do Amazon EBS



Os volumes compatíveis com HDD do Amazon EBS funcionarão bem quando o foco estiver na taxa de transferência.

	HDD com taxa de transferência otimizada (st1)	Cold HDD (sc1)
Descrição	 Tipo de volume de baixo custo Criada para cargas de trabalho frequentemente acessadas e com alto uso da taxa de transferência 	 Volume de HDD de menor custo Projetado para cargas de trabalho acessadas com menos frequência
Casos de uso	 Cargas de trabalho de streaming Big data Data warehouses Processamento de logs Não pode ser um volume de inicialização 	 Armazenamento focado na taxa de transferência para grandes volumes de dados acessados raramente Casos de uso nos quais o menor custo de armazenamento é importante Não pode ser um volume de inicialização

Instâncias otimizadas para o Amazon EBS



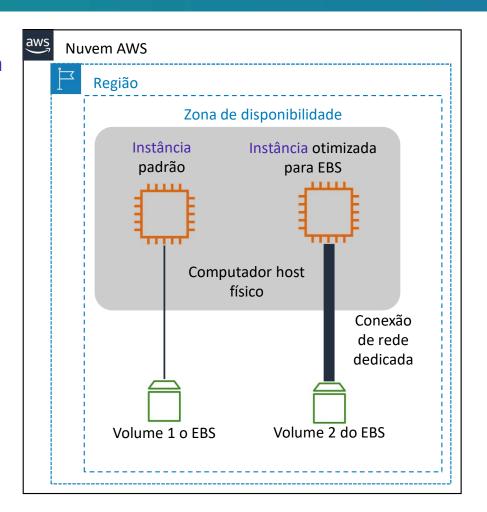
 Alguns tipos de instância do EC2 podem ser otimizados para o EBS

Benefícios:

- Fornece uma conexão de rede dedicada ao volume do EBS
- Melhora a performance de E/S
- Melhorias na performance serão obtidas se você usar um tipo de instância baseado em Nitro System do Amazon EC2

• Uso:

- Para tipos de instância otimizados para o EBS, a otimização é habilitada por padrão
- Para outros tipos de instâncias compatíveis, a otimização deve ser habilitada manualmente



Sistemas de arquivos compartilhados para instâncias do EC2



E se eu tiver várias instâncias que precisam usar o mesmo armazenamento?

Amazon EBS: só se associa a uma instância



Amazon S3: é uma opção, mas não é ideal



Amazon S3

Amazon EFS e Amazon FSx for Windows File Server:ambos cumprem o requisito



Amazon EFS



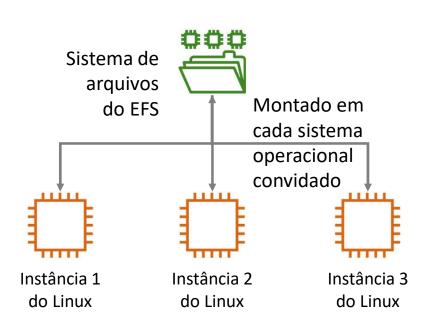


O Amazon EFS fornece armazenamento no sistema de arquivos para cargas de trabalho baseadas em Linux.

- Sistema de arquivos elástico totalmente gerenciado
- Aumentam ou reduzem automaticamente à medida que os arquivos são adicionados e removidos
- Petabytes de capacidade
- Compatível com protocolos NFS (Network File System)
 - Monte o sistema de arquivos na instância do EC2
- Compatível com todas as AMIs baseadas em Linux para o Amazon EC2

Casos de uso do Amazon EFS





Cargas de trabalho e aplicações:

- Diretórios iniciais
- Sistema de arquivos para aplicações empresariais
- Testes e desenvolvimento de aplicações
- Backups de bancos de dados
- Gerenciamento de conteúdo e serviços na Web
- Fluxos de trabalho de mídia
- Análise de dados do big data

Exemplo de comando para montar o sistema de arquivos em cada SO convidado:

\$ sudo mount -t nfs4 mount-target-DNS:/ ~/efs-mount-point

Amazon FSx for Windows File Server





Fornece armazenamento do sistema de arquivos compartilhado totalmente gerenciado para instâncias do Microsoft Windows EC2.

- Compatibilidade nativa do Microsoft Windows
- Novo sistema de arquivos de tecnologia (NTFS)
- Versão 2.0 a 3.1.1 do protocolo SMB (Bloco de Mensagens do Servidor Nativo)
- Namespaces de sistema de arquivos distribuídos (DFS) e replicação DFS
- Integra-se ao Microsoft Active Directory e é compatível com listas de controle de acesso (ACLs) do Windows
- Compatível com o armazenamento SSD de alta performance

Guia do usuário do Amazon FSx for Windows File Server

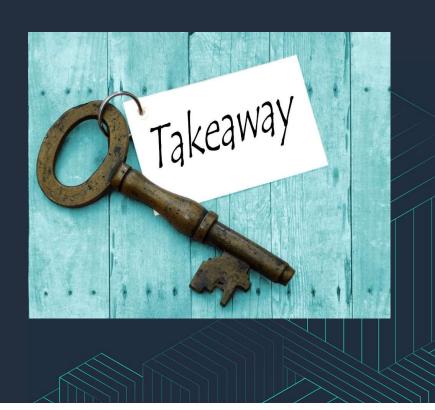


O Amazon FSx for Windows File Server oferece suporte a um amplo conjunto de cargas de trabalho do Microsoft Windows.

- Diretórios iniciais
- Cargas de trabalho de aplicações lift-and-shift
- Fluxos de trabalho de mídia e entretenimento
- Análise de dados
- Gerenciamento de conteúdo e serviços na Web
- Ambientes de desenvolvimento de software



Principais lições da Seção 6





- As opções de armazenamento para instâncias do EC2 incluem armazenamento de instâncias, Amazon EBS, Amazon EFS e Amazon FSx for Windows File Server
- Para um volume raiz, use o armazenamento de instâncias ou o Amazon EBS compatível com SSD
- Para um volume de dados que atenda apenas a uma instância, use o armazenamento de instâncias ou o armazenamento do Amazon EBS
- Para um volume de dados que atenda a várias instâncias do Linux, use o Amazon EFS
- Para um volume de dados que atenda a várias instâncias do Microsoft Windows, use o Amazon ESx for Windows File Server

Módulo 6: Criar um ambiente de redes

Seção 2: Criar um ambiente de rede da AWS



Amazon VPC



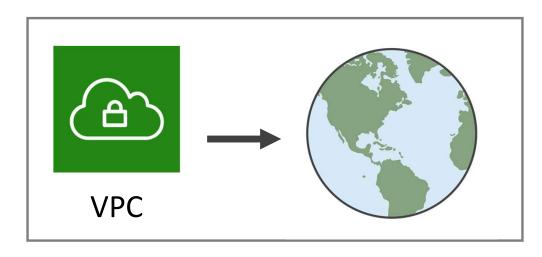
Provisione uma seção logicamente isolada da Nuvem AWS na qual seja possível executar recursos da AWS em uma rede virtual que você mesmo define.

Traga sua própria rede

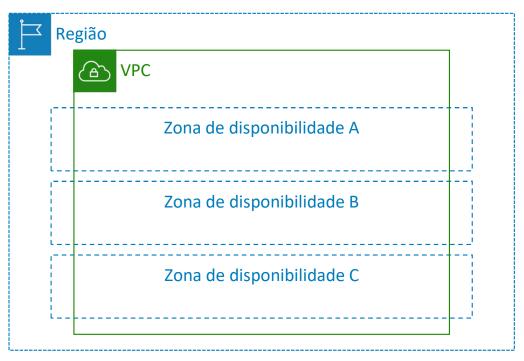


Implantação de VPC





Você pode implantar uma VPC em qualquer região da AWS.



Uma VPC pode hospedar recursos compatíveis de qualquer zona de disponibilidade dentro de sua própria região.

Roteamento sem classe entre domínios (CIDR)



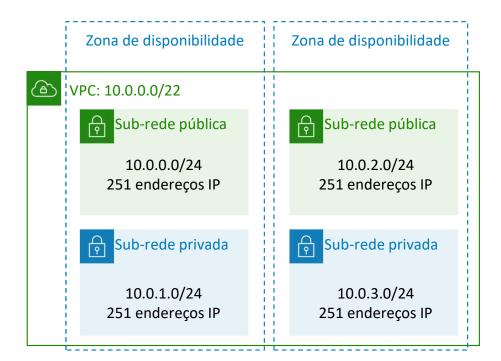
0.0.0.0/0	= Todos os endereços IP
10.22.33.44/32	= 10.22.33.44
10.22.33.0/24	= 10.22.33.*
10.22.0.0/16	= 10.22.*.*

CIDR	Total de endereços IP
/28	16
/20	4.096
/19	8.192
/18	16.384
/17	32.768
/16	65.536

Sub-redes: divisão de sua VPC



- Uma sub-rede é um segmento ou partição do intervalo de endereços IP de uma VPC em que você pode alocar um grupo de recursos.
- As sub-redes não são limites de isolamento
- As sub-redes s\(\tilde{a}\) o um subconjunto do bloco CIDR da VPC
- Não é possível sobrepor blocos CIDR de sub-rede
- Cada sub-rede reside inteiramente dentro de uma zona de disponibilidade
- É possível adicionar uma ou mais sub-redes em cada zona de disponibilidade ou em uma zona local
- A AWS reserva cinco endereços IP em cada sub-rede



Exemplo: uma VPC com CIDR /22 inclui um total de 1.024 endereços IP.

Melhores práticas de design da VPC



- Crie uma sub-rede por zona de disponibilidade disponível para cada grupo de hosts que tenham requisitos exclusivos de roteamento.
- Divida o intervalo de rede da VPC uniformemente entre todas as zonas de disponibilidade disponíveis em uma região.
- Não aloque todos os endereços de rede de uma só vez. Em vez disso, reserve um pouco de espaço de endereço para uso futuro.
- Dimensione as sub-redes e o CIDR da VPC de modo a auxiliar um crescimento significativo para as cargas de trabalho esperadas.
- Certifique-se de que o intervalo de rede da VPC (bloco CIDR) não se sobreponha a outros intervalos de rede privada da sua organização.

Implantação de VPC única



Há casos de uso limitados em que a implantação de uma VPC pode ser apropriada:

- Aplicações pequenas e únicas gerenciadas por uma equipe pequena
- Computação de Alta Performance (HPC)
- Gerenciamento de identidades

Na maioria dos casos de uso, há dois padrões principais para organizar sua infraestrutura: várias VPCs e várias contas.

Várias VPCs

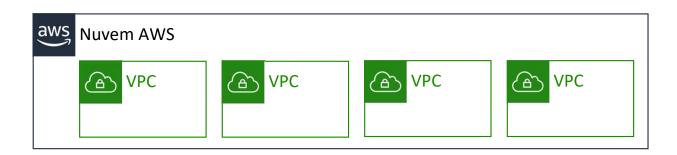


• Ideal para:

- Uma única equipe ou organização, como provedores de serviços gerenciados
- Equipes limitadas, o que facilita a manutenção dos padrões e o gerenciamento do acesso

Exceção:

• Padrões de governança e conformidade podem exigir maior isolamento das cargas de trabalho, independentemente da complexidade organizacional



Várias contas



- Ideal para:
 - Organizações grandes e organizações com várias equipes de TI
 - Organizações de médio porte que esperam um crescimento rápido
- Por quê?
 - Pode ser mais desafiador gerenciar o acesso e os padrões em organizações mais complexas





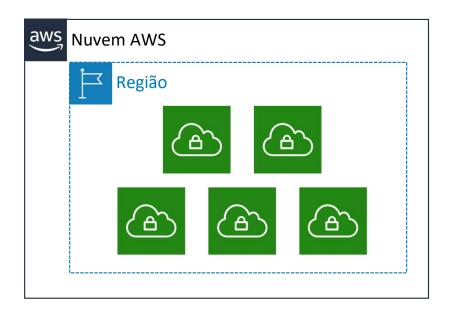




Cotas da Amazon VPC

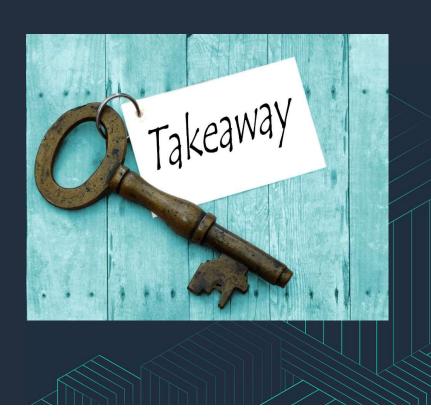


Cota padrão: 5 VPCs por região por conta *



^{*} A cota padrão é de 5 VPCs por região, mas você pode solicitar um aumento.

Principais lições da Seção 2





- A Amazon VPC permite provisionar VPCs, que são seções isoladas logicamente da Nuvem AWS, em que é possível executar os recursos da AWS.
- Uma VPC pertence a apenas uma região e é dividida em sub-redes.
- Uma sub-rede pertence a uma zona de disponibilidade ou zona local. Ela é um subconjunto do bloco CIDR da VPC.
- Você pode criar várias VPCs na mesma região ou em regiões diferentes e na mesma conta ou em contas diferentes.
- Siga as melhores práticas ao projetar sua VPC.

Módulo 6: Criar um ambiente de redes

Seção 3: Conectar o ambiente de rede da AWS à Internet



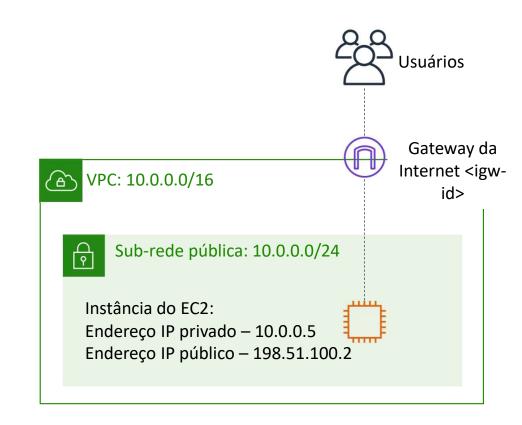
Criar uma sub-rede pública





Gateways da Internet

- Permitem a comunicação entre recursos em sua VPC e na Internet
- São dimensionados horizontalmente, redundantes e altamente disponíveis por padrão
- Fornecem um alvo nas tabelas de rotas de sub-rede para o tráfego roteável pela Internet



Direcionamento de tráfego entre recursos da VPC



- Tabelas de rotas são necessárias para direcionar o tráfego entre recursos da VPC
- Cada VPC tem uma tabela de rotas principal (padrão)
- Todas as sub-redes devem ser associadas a uma tabela de rotas
- Você pode criar tabelas de rotas personalizadas

Melhor prática: use tabelas de rotas personalizadas para cada sub-rede.

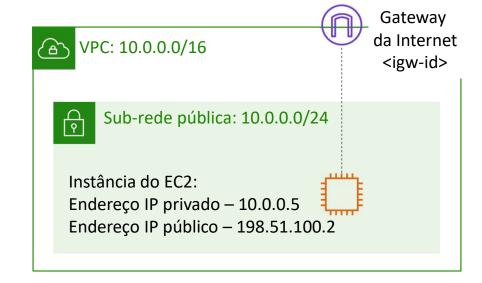


Tabela de rotas pública

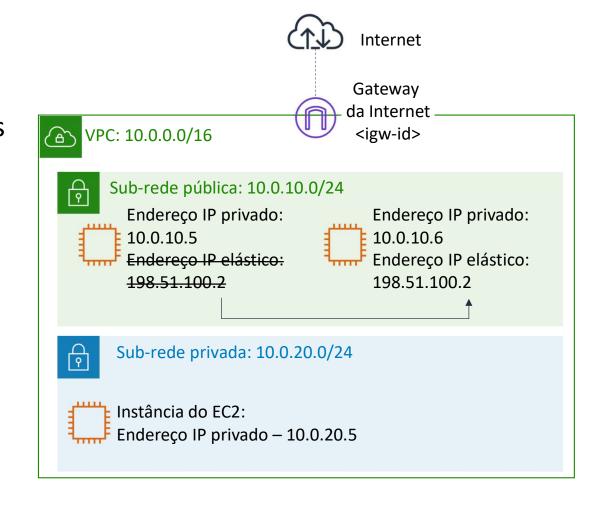
Destino	Alvo
10.0.0.0/16	local
0.0.0.0/0	<igw-id></igw-id>

Remapeamento de um endereço IP de uma instância para outra



○→ Endereços IP elásticos

- São endereços IPv4 públicos e estáticos associados à sua conta da AWS
- Podem ser associados a uma instância ou a uma interface de rede elástica
- Podem ser remapeados para outra instância em sua conta
- São úteis para redundância quando balanceadores de carga não são uma opção



Conexão de sub-redes privadas à Internet





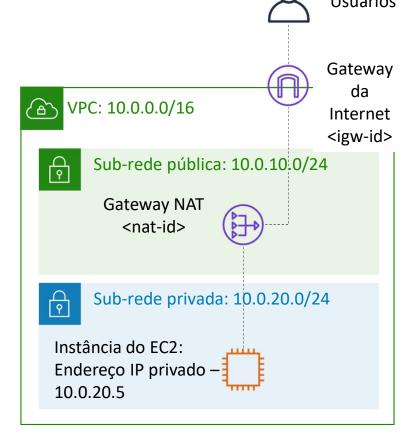
- Permitem que instâncias em uma sub-rede privada iniciem tráfego de saída para a Internet ou outros serviços da AWS
- Impedem que instâncias privadas recebam solicitações de conexão de entrada da Internet

Tabela de rotas pública

Destino	Alvo
10.0.0.0/16	local
0.0.0.0/0	<igw-id></igw-id>

Tabela de rotas privada

Destino	Alvo
10.0.0.0/16	local
0.0.0.0/0	<nat-id></nat-id>



Exemplos de caso de uso de sub-rede (1 de





Instâncias de armazenamento de dados



Instâncias de processamento em lote



Instâncias de back-end



Instâncias de aplicações Web

Exemplos de caso de uso de sub-rede (2 de





Instâncias de armazenamento de dados

Sub-rede privada



Instâncias de processamento em lote

Sub-rede privada



Instâncias de back-end ————

Sub-rede privada



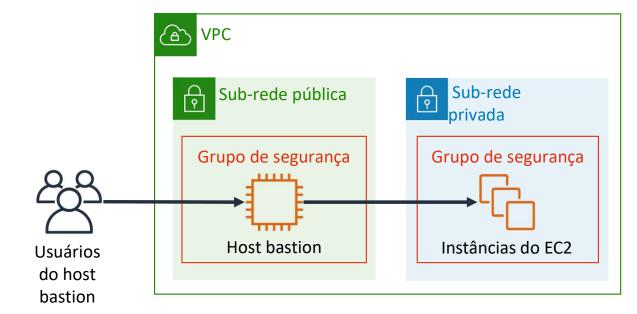
Instâncias de aplicações Web

Sub-rede pública ou privada

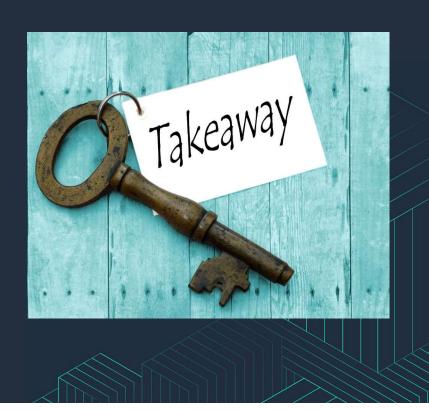
Hosts bastion



- Um servidor com o objetivo de fornecer acesso a uma rede privada a partir de uma rede externa
- Deve minimizar as chances de penetração



Principais lições da Seção 3





- Um gateway da Internet permite a comunicação entre instâncias na VPC e na Internet.
- As tabelas de rotas controlam o tráfego da sub-rede ou do gateway.
- Os endereços IP elásticos são endereços IPv4
 públicos e estáticos que podem ser associados a
 uma instância ou a uma interface de rede elástica.
 Eles podem ser remapeados para outra instância
 em sua conta.
- Os gateways NAT permitem que instâncias na subrede privada iniciem tráfego de saída para a Internet ou outros serviços da AWS.
- Um host bastion é um servidor com o objetivo de fornecer acesso a uma rede privada a partir de uma rede externa, como a Internet.

Módulo 9: Implementar elasticidade, alta disponibilidade e monitoramento

Seção 2: Dimensionar recursos de computação



O que é elasticidade?



Uma infraestrutura elástica pode se expandir e se contrair conforme as necessidades de capacidade mudam.

Exemplos:

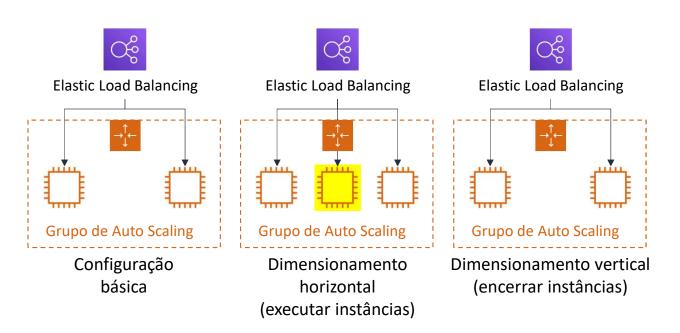
- Aumento do número de servidores Web quando há picos de tráfego
- Redução da capacidade de gravação em seu banco de dados quando o tráfego diminui
- Cuidado com a flutuação diária da demanda em toda a sua arquitetura

O que é escalabilidade?

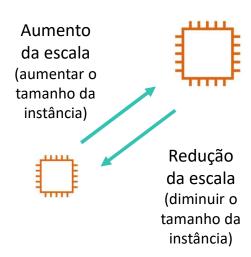


Uma técnica utilizada para alcançar a elasticidade

Escalabilidade horizontal



Escalabilidade vertical



Amazon EC2 Auto Scaling





- Executa ou encerra instâncias com base nas condições especificadas
- Registra novas instâncias automaticamente com balanceadores de carga quando especificado
- É possível executar entre zonas de disponibilidade

Opções de escalabilidade



Programada

Boa para cargas de trabalho previsíveis



Dimensiona com base em data e hora

Caso de uso: desligamento de suas instâncias de desenvolvimento e teste à noite

Dinâmica

Boa para mudanças de condições



Compatível com monitoramento de alvo

Caso de uso: escalabilidade baseada na utilização da CPU

Preditiva

Boa para a demanda prevista



Dimensionamento baseado em machine learning

Caso de uso: cuidados com aumento na carga de trabalho do site de comércio eletrônico durante um grande evento de vendas

Tipos de política de escalabilidade dinâmica



- Escalabilidade simples ajuste de escalabilidade única
 - Exemplos de casos de uso: novas cargas de trabalho, picos de cargas de trabalho
- Escalabilidade da etapa o ajuste depende do tamanho da violação do alarme
 - Exemplo de caso de uso: cargas de trabalho previsíveis
- Escalabilidade de monitoramento de alvo valor de alvo para métrica específica
 - Exemplo de caso de uso: aplicações escaláveis horizontalmente, como aplicações com carga balanceada e de processamento de dados em lote

Grupos de Auto Scaling



Um grupo de Auto Scaling define o seguinte:

- Capacidade mínima
- Capacidade máxima
- Capacidade desejada*

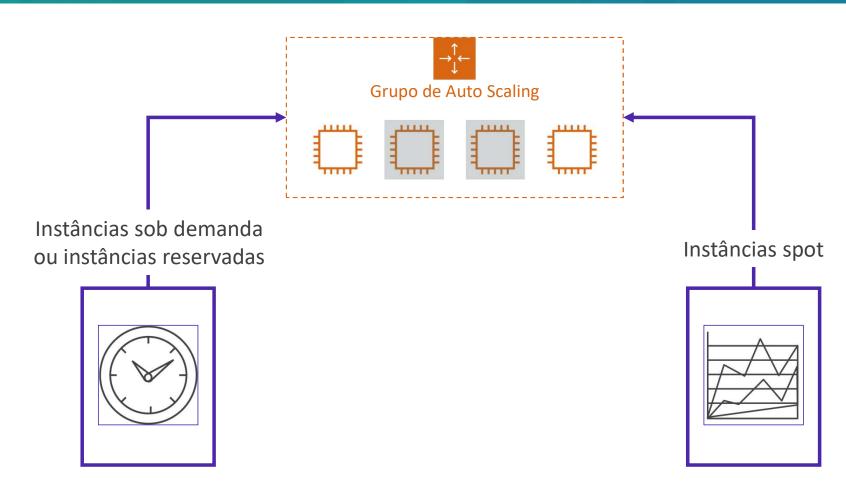
Capacidade?



^{*}A capacidade desejada reflete o número de instâncias que estão em execução e podem flutuar em resposta a eventos.

Amazon EC2 Auto Scaling: opções de compra





Considerações sobre escalabilidade automática



- Vários tipos de escalabilidade automática
- Escalabilidade simples, em etapas ou de monitoramento de alvo
- Várias métricas (não apenas CPU)
- Quando dimensionar na horizontal e na vertical
- Uso de ganchos de ciclo de vida

Principais lições da Seção 2





- Uma infraestrutura elástica pode se expandir e se contrair conforme as necessidades de capacidade mudam
- O Amazon EC2 Auto Scaling adiciona ou remove automaticamente instâncias do EC2 de acordo com as políticas definidas, programações e verificações de integridade
- O Amazon EC2 Auto Scaling oferece várias opções de escalabilidade para melhor atender às necessidades das suas aplicações
- Ao configurar um grupo de Auto Scaling, você pode especificar os tipos de instância do EC2 e a combinação de modelos de definição de preço que ele usa

Módulo 9: Implementar elasticidade, alta disponibilidade e monitoramento

Seção 4: Projetar um ambiente altamente disponível



Sistemas altamente disponíveis



- Podem resistir a alguma medida de degradação enquanto permanecem disponíveis
- Têm tempo de inatividade mínimo
- Exigem intervenção humana mínima
- Recuperam-se de falha ou passam para origem secundária em uma quantidade aceitável de tempo de performance degradada

Porcentagem de tempo de atividade	Tempo de inatividade máximo por ano	Equivalente de tempo de inatividade por dia
90%	36,5 dias	2,4 horas
99%	3,65 dias	14 minutos
99,9%	8,76 horas	86 segundos
99,99%	52,6 minutos	8,6 segundos
99,999%	5,25 minutos	0,86 segundo

Elastic Load Balancing





Elastic Load Balancing

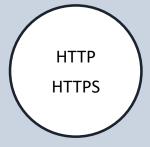
Um serviço de balanceamento de carga gerenciado que distribui o tráfego de entrada das aplicações por várias instâncias do EC2, contêineres, endereços IP e funções do Lambda.

- Pode ser externo ou interno
- Cada balanceador de carga recebe um nome DNS
- Reconhece e responde a instâncias não íntegras

Tipos de balanceadores de carga

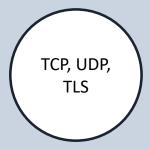


Application Load Balancer



- Gerenciamento flexível de aplicação
- Balanceamento de carga avançado de tráfego HTTP e HTTPS
- Opera no nível da solicitação (camada 7)

Network Load Balancer



- Performance ultraelevada e endereço IP estático para sua aplicação
- Balanceamento de carga do tráfego TCP, UDP e TLS
- Opera no nível da conexão (camada 4)

Classic Load Balancer

GERAÇÃO ANTERIOR para HTTP, HTTPS, TCP e SSL

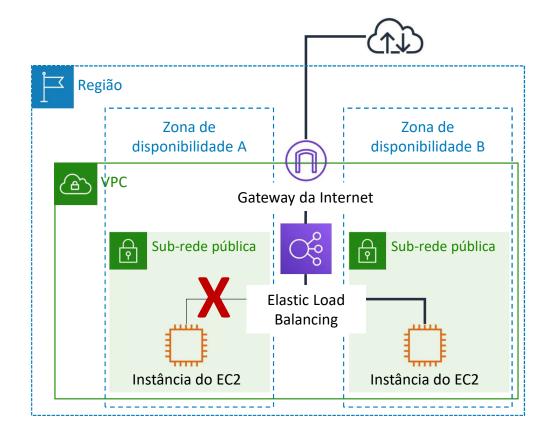
- Balanceamento de carga entre várias instâncias do EC2
- Opera no nível da solicitação e da conexão

Implementação de alta disponibilidade



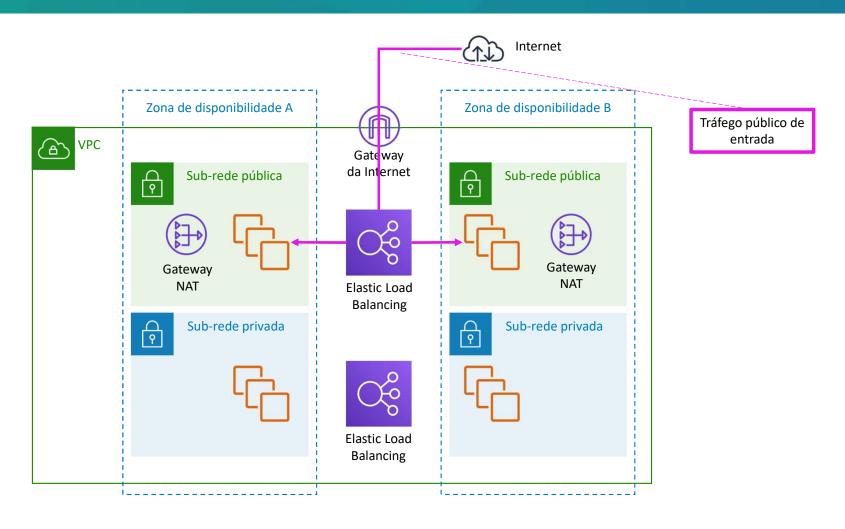
Comece com duas zonas de disponibilidade por região da AWS.

Se os recursos em uma Zona de disponibilidade estiverem inacessíveis, sua aplicação não deverá falhar.



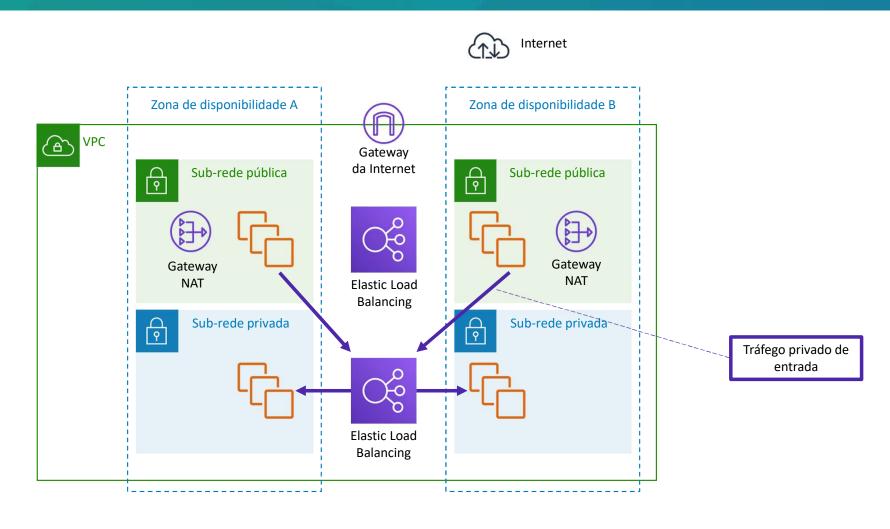
Exemplo de uma arquitetura altamente disponível (1 de 3)





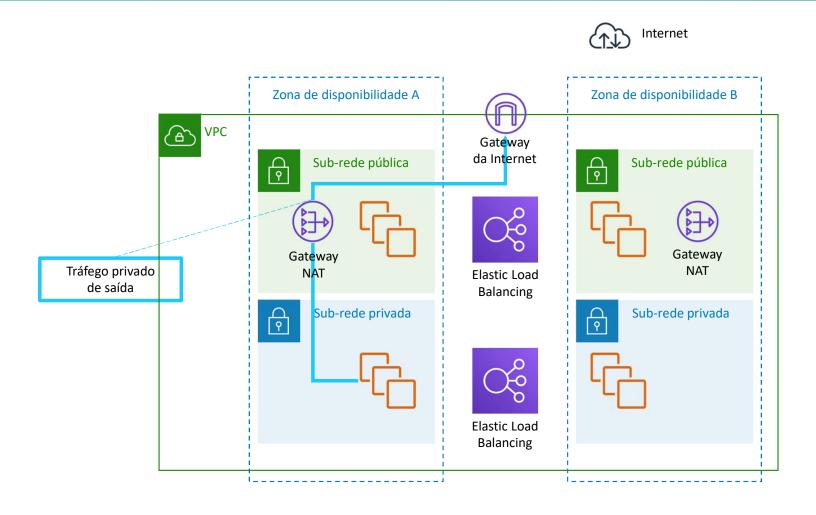
Exemplo de uma arquitetura altamente disponível (2 de 3)





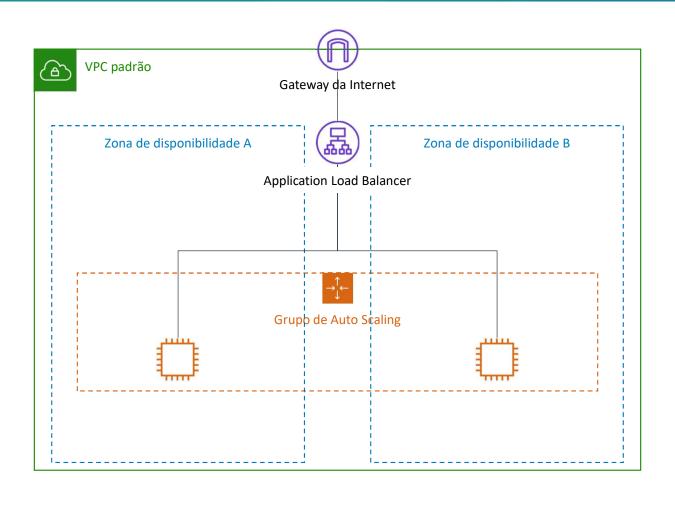
Exemplo de uma arquitetura altamente disponível (3 de 3)





Arquitetura de demonstração





Amazon Route 53





O Amazon Route 53 é um serviço de DNS na nuvem altamente disponível e escalável.

- Converte nomes de domínio em endereços IP
- Conecta solicitações de usuários à infraestrutura executada dentro e fora da AWS
- Pode ser configurado para encaminhar o tráfego para endpoints saudáveis ou para monitorar a integridade da aplicação e os endpoints dela
- Oferece registro de nomes de domínio
- Tem várias opções de roteamento

Roteamento compatível com o Amazon Route 53

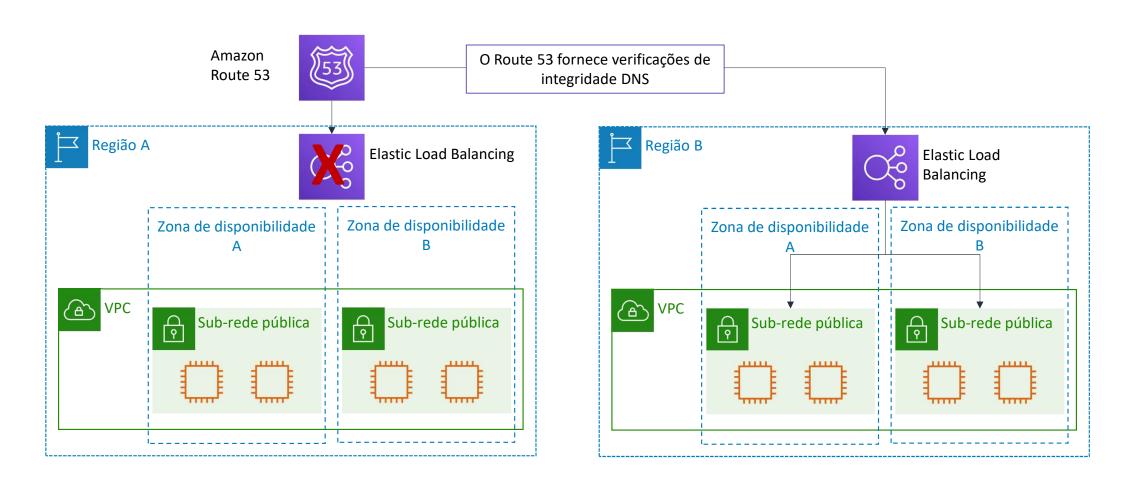


- Roteamento simples
- Roteamento round robin ponderado
- Roteamento baseado em latência
- Roteamento por geolocalização
- Roteamento de geoproximidade
- Roteamento de failover
- Roteamento de resposta com vários valores



DNS e alta disponibilidade multirregional





Principais lições da Seção 4





- Você pode projetar suas arquiteturas de rede para ficarem altamente disponíveis e evitar pontos únicos de falha
- O Route 53 oferece várias opções de roteamento que podem ser combinadas com failover de DNS para permitir arquiteturas de baixa latência e tolerantes a falhas

Módulo 4: Adicionar uma camada de computação

Seção 8: Considerações sobre o Amazon EC2



Placement groups



Os placement groups permitem controlar onde as instâncias são executadas em uma zona de disponibilidade.

- Eles influenciam onde um grupo de instâncias interdependentes executará
 - Aprimore a performance da rede entre eles
 - Reduze a falha correlacionada ou simultânea
- Estratégias de posicionamento
 - Cluster
 - Partição
 - Propagação
- Limitações
 - Uma instância pode ser executada em apenas um placement group por vez
 - As instâncias com uma locação de host não podem ser executadas em placement groups



Placement group de cluster



Os placement groups de cluster fornecem baixa latência e alta performance de rede de pacote por segundo entre instâncias na mesma zona de disponibilidade.



- As instâncias são colocadas no mesmo segmento de largura de banda de alta bisseção da rede
- Fornece limite de taxa de transferência por fluxo de até 10 Gbps para tráfego TCP/IP
- Recomendados para aplicações que se beneficiam de baixa latência de rede, alta taxa de transferência de rede ou ambas
- Melhor prática: executar todas as instâncias em uma única solicitação

Placement group de partição



Um placement group de partição distribui as instâncias em partições lógicas para reduzir a probabilidade de falhas de hardware correlacionadas.



- Cada partição tem seu próprio conjunto de racks (rede e fonte de energia)
- Cada rack tem sua própria rede e fonte de energia
- As partições podem estar em várias zonas de disponibilidade
- Elas são recomendados para cargas de trabalho grandes, distribuídas e replicadas

Placement group de distribuição



Os placement groups de distribuição colocam as instâncias em racks físicos distintos para reduzir as falhas de hardware correlacionadas.





- Cada rack tem sua própria rede e fonte de energia
- O grupo pode abranger várias zonas de disponibilidade
- Recomendados para aplicações com poucas instâncias críticas que devem ser mantidas separadas umas das outras

Módulo 10: Automatizar a arquitetura

Seção 5: AWS Elastic Beanstalk



Desafios gerais





O gerenciamento da infraestrutura

baseado na implantação da aplicação pode ser *difícil*



Pode ser *demorado* gerenciar e configurar servidores

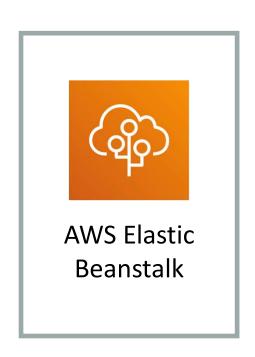


Você pode *não ter consistência* em muitos projetos ou aplicações



AWS Elastic Beanstalk





- Uma maneira fácil de colocar as aplicações Web em execução
- Um serviço gerenciado que lida automaticamente com:
 - Provisionamento e configuração da infraestrutura
 - Implantação
 - Balanceamento de carga
 - Escalabilidade automática
 - Monitoramento de integridade
 - Análise e depuração
 - Registro em log

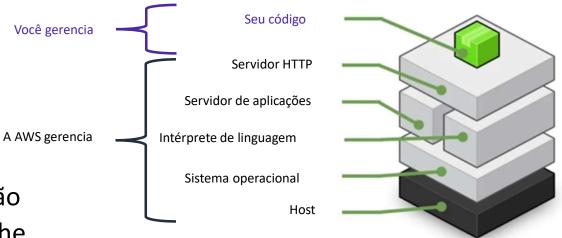


- Não há custo adicional para usá-lo
 - Pague somente pelos recursos subjacentes usados

Implantações do AWS Elastic Beanstalk

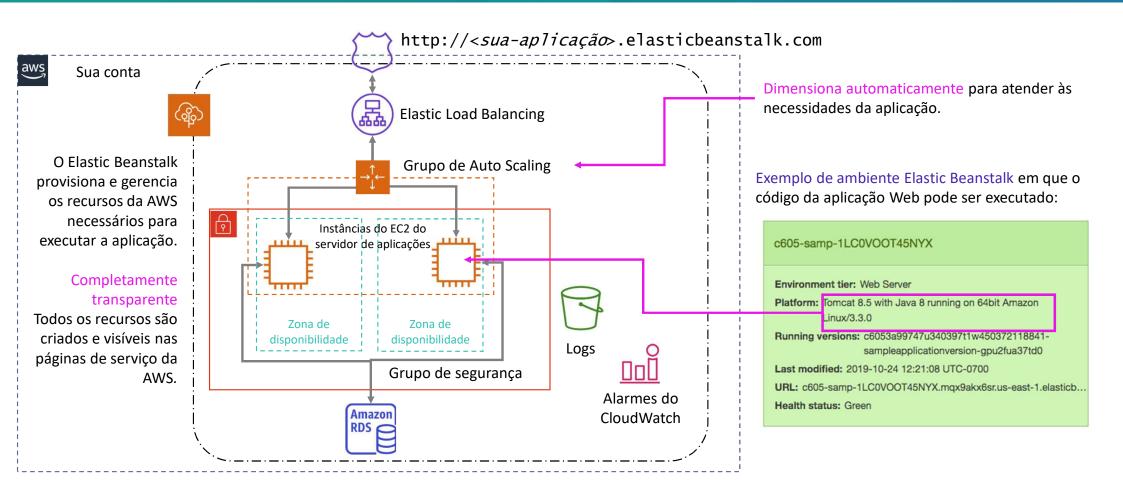


- Ele oferece suporte a aplicações Web criadas para plataformas comuns
 - Java, .NET, PHP, Node.js,
 Python, Ruby, Go e Docker
- Faça upload do seu código
 - O Elastic Beanstalk lida automaticamente com a implantação
 - Implanta em servidores como Apache, NGINX, Passenger, Puma e Microsoft Internet Information Services (IIS)



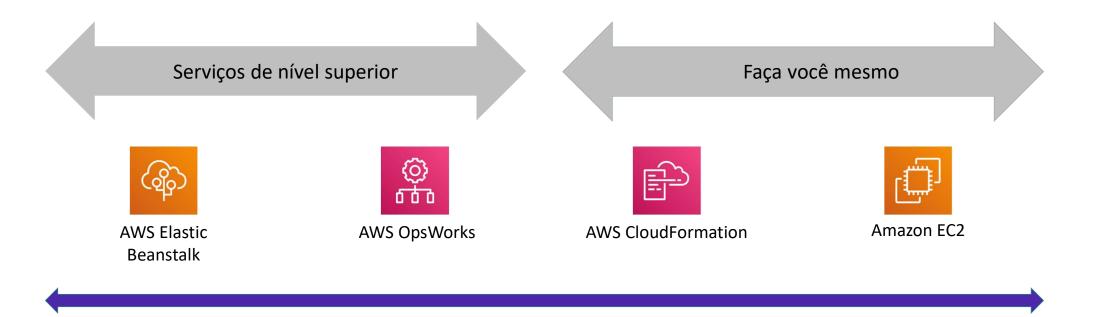
Ambiente de aplicação Elastic Beanstalk





Escolher a solução de automação adequada

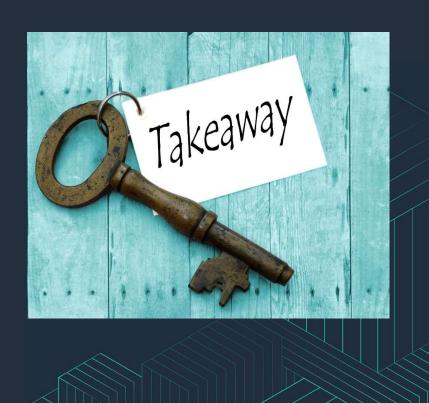




Conveniência

Controle

Principais lições da Seção 5





- O Elastic Beanstalk cria e gerencia um ambiente de aplicação Web escalável e altamente disponível que permite que você se concentre no código da aplicação
- Você pode criar o código da aplicação do Elastic Beanstalk em Java, .NET, PHP, Node.js, Python, Ruby, Go, ou Docker
- Os recursos da AWS criados pelo Elastic Beanstalk são totalmente transparentes. Eles são visíveis nas exibições de páginas de serviço do Console de Gerenciamento da AWS
- Sem cobrança extra para o Elastic Beanstalk. Pague apenas pelos recursos subjacentes usados